

3.3.

$$1. a(x) = \text{sign } f(x), \text{ где } f(x) = w_0 + \langle w, x \rangle$$

$$2. M_i = y_i f(x_i)$$

Если $\text{sign } M_i > 0$, то класс был предсказан верно

Если $\text{sign } M_i < 0$, то неверно.

3. Было: $w_0 + \langle w, x \rangle$

Стало: $\langle \tilde{w}, \tilde{x} \rangle$ ← добавили фиктивную координату k

$$\tilde{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \Rightarrow \tilde{x} = \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{pmatrix}, \tilde{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{pmatrix}$$

$$4. Q(x) = \frac{1}{m} \sum_{i=1}^m I(M_i \leq 0)$$

Чтобы алгоритм был оптимальным (все предсказания верны), нужно, чтобы $Q(x) = 0$.

5. Если все $M_i < 0$, то, положив $w = \vec{0}$, получим $\forall i M_i = 0 \Rightarrow Q(x) = 0$.

$$6. Q = \frac{1}{m} \sum_{i=1}^m L(M_i)$$

7. Ф-я потерь $L(a(x))$ — величина ошибки алгоритма a на объекте x .
Ф-ия $L(a, x) \geq 0$ и не возрастает.

$$8. L(M) = (1 - M)_+$$

9. Регуляризация — добавление нек-рой дополнительной информации к условию с целью решить некорректно поставленную задачу (шум, разделение непрерывности выборки со смещением классов) или предотвратить переобучение.

Примеры: l_1 -регуляризация: $\delta \cdot \sum_{k=1}^n |w_k|$

l_2 -регуляризация: $\delta \cdot \sum_{k=1}^n |w_k|^2$

10. Пусть X и Y — непересекающиеся выборки. Обобщающая способность алгоритма a определяется функционалом $Q(a(x), Y)$. Переобученный алгоритм приводит к большому значению Q . Добавление регуляризатора решает проблему переобучения, не позволяя какому-то из вэгов сильно превосходить остальные.

11. Т.к. минимизи острый, то даже небольшое отклонение от точки минимума приведет к резкому увеличению значения функционала и переобучению.

12. Увеличивается по мере приближения весов к определенным границам и выходе за них.

13. Для построенного с регуляризацией, т.к. регуляризатор ≥ 0 .

14. Рассмотрим случай обучения без регуляризатора:

Если при отсутствии регуляризатора алгоритм перейдет на обучающей выборке, то на тестовой выборке получим плохой результат \Rightarrow значение без регуляризатора может быть больше.

Если же при отсутствии регуляризатора алгоритм не перейдет, то значение функционала с регуляризатором может быть больше. \Rightarrow возможны оба случая

Вопросы 15, 16 и 17 совпадают с вопросами 1, 2 и 3 задачи 3.6 соответственно.


15. Accuracy = $\frac{\# \text{правильные ответы}}{\# \text{все ответы}}$ - доля правильных ответов

Precision = $\frac{(\text{true positive})}{(\text{true positive}) + (\text{false positive})}$

Recall = $\frac{(\text{true positive})}{(\text{true positive}) + (\text{false negative})}$, где

Информированный класс	Реальный класс	
	1	0
1	true positive	false positive
0	false negative	true negative

16. ROC-AUC - метрика, оценивающая качество классификации (в задачах бинарной классификации) по вероятности принадлежности к целевой классу.



ROC-AUC = площадь под графиком

TPR = $\frac{tp}{tp+fn}$ - true positive rate

FPR = $\frac{fp}{fp+tn}$ - false positive rate

17. Рассмотрим выборку X из m объектов.
Пусть $m_- = \sum_{i=1}^m I(y_i = -1)$, $m_+ = \sum_{i=1}^m I(y_i = 1)$

1) Упорядочим выборку X по убыванию значения $\langle x_i, w \rangle$

2) Начальное значение ROC-кривой:
(FPR₀, TPR₀) := (0, 0)
AUC := 0

3) for i in $(1, m)$:

if $(y_i = -1)$:

FPR_i = FPR_{i-1} + $\frac{1}{m_-}$

TPR_i = TPR_{i-1}

AUC = AUC + $\frac{1}{m_-}$ TPR_i

else:

FPR_i = FPR_{i-1}

TPR_i = TPR_{i-1} + $\frac{1}{m_+}$

- получим ROC-кривую

} сдвигаемся на 1 шаг вправо

} сдвигаемся на 1 шаг вверх

3.2

Пусть $p(x, y | w)$ - совместное распредел. x и y ,
 $\{q_\ell(w) | \ell \in A\}$ - семейство априорных распредел. w .
Будем считать, что выборка может иметь
модуль m $p(x, y | w)$ точек с
вероятностью $q_\ell(w)$.

Будем искать w с помощью метода
максимального правдоподобия:

$$f = \prod_{i=1}^m p(x_i, y_i | w) \cdot q_\ell(w)$$

$$\tilde{L}(w) = \ln f = \sum_{i=1}^m [\ln p(x_i, y_i | w) + q_\ell(w)] \rightarrow \max$$

Положим $L(x_i, y_i, w) = -\ln p(x_i, y_i | w)$

$$\mathcal{L}_\xi(w) = -\ln q_\ell(w)$$

Получаем задачу оптимизации:

$$Q(w) = \sum_{i=1}^m [L(x_i, y_i, w) + \mathcal{L}_\xi(w)] \rightarrow \min$$

П.е. функцией ξ имеет вероятностной
семейств априорного распредел. параметра w

\mathcal{L}_ℓ - функцией - соотв. n -мерному
распределению Лапласа:

$$q(w) = \left(\frac{1}{2\sigma}\right)^n \exp\left(-\frac{\|w\|_1}{\sigma}\right)$$

$$-\ln q(w) = \frac{1}{\sigma} \sum_{i=1}^n |w_i| + \tilde{C}(w)^{\text{const}}$$

\mathcal{L}_2 - функцией - соотв. n -мерному
распредел. Гаусса:

$$q(w) = \left(\frac{1}{2\pi\sigma^2}\right)^n \exp\left(-\frac{\|w\|_2^2}{2\sigma^2}\right)$$

$$-\ln q(w) = \frac{1}{2\sigma^2} \|w\|_2^2 + \tilde{C}(w)$$

3.3 Пусть $X \subseteq \mathbb{R}^n$, $y = \{-1, 1\}$

$$a(x) = \text{sign}(\langle w, x \rangle - w_0)$$

Предположим, что выборка может быть линейно разделена, т.е.

$$\exists w, w_0: Q(w, w_0) = 0, \text{ где } Q(w, w_0) = \sum_{i=1}^m I(y_i(\langle w, x_i \rangle - w_0) \leq 0)$$

Будем искать оптимальное положение гиперплоскости.

Отнофицируем параметры w и w_0 так, чтобы

$$\min y_i(\langle w, x_i \rangle - w_0) = 1$$

Сформулируем задачу:



$$\begin{aligned} \langle x_+ - x_-, \frac{w}{\|w\|} \rangle &= \frac{\langle w, x_+ \rangle}{\|w\|} - \frac{\langle w, x_- \rangle}{\|w\|} = \\ &= \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|} \end{aligned}$$

\rightarrow для увеличения ширины разделяющей полосы нужно минимизировать $\|w\|$.

Формулируем задачу:

$$\begin{cases} \frac{1}{2} \|w\|^2 \rightarrow \min_{w, w_0} \\ y_i(\langle w, x_i \rangle - w_0) \geq 1 \end{cases}$$

Для случая линейно неразделимой выборки введем штраф за ошибки:

$$\begin{cases} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \varepsilon_i \rightarrow \min_{w, w_0, \varepsilon} \\ y_i(\langle w, x_i \rangle - w_0) \geq 1 - \varepsilon_i \\ \varepsilon_i \geq 0 \end{cases}$$

Сведем задачу к задаче безусловной оптимизации:

$$\begin{cases} \varepsilon_i \geq 1 - y_i(\langle w, x_i \rangle - w_0) \\ \varepsilon_i \geq 0 \end{cases}$$

П.к. $M_i = y_i(\langle w, x_i \rangle - w_0)$, то имеем задачу

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^m (1 - M_i(w, w_0))_+ \rightarrow \min_{w, w_0}$$

(3.4)

$$x_1^2 + 2x_2^2 = 3$$

Рассмотрим квадратичную афф.

$$K(x, y) = \langle x, y \rangle^2 = (x_1 y_1 + x_2 y_2)^2 = x_1^2 y_1^2 + 2x_1 x_2 y_1 y_2 + x_2^2 y_2^2 = \\ = \langle (x_1^2, x_2^2, \sqrt{2} x_1 x_2), (y_1^2, y_2^2, \sqrt{2} y_1 y_2) \rangle$$

Получим отображение $\varphi: \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rightarrow \begin{pmatrix} x_1^2 \\ x_2^2 \\ \sqrt{2} x_1 x_2 \end{pmatrix} \in \mathbb{R}^3$

В спримизирующем преобразовании поверхность будет иметь вид гиперплоскости

$$\langle \tilde{x}, w \rangle - w_0 = 0$$

$$\langle (x_1^2, x_2^2, \sqrt{2} x_1 x_2), (w_1, w_2, w_3) \rangle - w_0 = 0$$

$$\Rightarrow w = \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \\ 0 \end{pmatrix} \quad w_0 = -3.$$

(3.5)

из м. К.К.П.

$$\begin{cases} f(x) \rightarrow \min \\ g(x) < 0 \end{cases} \Leftrightarrow \begin{cases} \nabla_x L(x, \mu) = \nabla_x (f(x) + \mu g(x)) = 0 \\ \mu g(x) = 0 \\ \mu \geq 0 \end{cases}$$

Рассмотрим задачу:

$$\begin{cases} \sum_{i=1}^m L(x_i, y_i, w) \rightarrow \min \\ \sum_{i=1}^m |w_i| \leq d \end{cases} \Leftrightarrow \begin{cases} \sum_{i=1}^m L(x_i, y_i, w) \rightarrow \min \\ \sum_{i=1}^m |w_i| - d \leq 0 \end{cases} \quad (*)$$

Задача (*) эквивалентна задаче (по м. К.К.П.):

$$(**) \begin{cases} \sum_{i=1}^m L(x_i, y_i, w) + \mu \sum_{i=1}^m |w_i| - d\mu \rightarrow \min \\ \mu (\sum_{i=1}^m |w_i| - d) = 0 \\ \mu \geq 0 \end{cases}$$

из (**) видно, что $\left[\sum_{i=1}^m |w_i| = d \right]_{\mu=0}$

$$\Rightarrow \text{имеем задачу} \begin{cases} \sum_{i=1}^m L(x_i, y_i, w) + \mu \sum_{i=1}^m |w_i| \rightarrow \min \\ \mu \geq 0 \\ \left[\sum_{i=1}^m |w_i| = d \right]_{\mu=0} \end{cases}$$

с L_1 -нормой.